

딥페이크 판별 프로젝트 종합 리포트

공간 × 시간 이중브랜치 탐지기 — 진단에서 제품까지

한 줄 요약. FaceForensics++로 학습한 딥페이크 판별기를 만들되, "무엇이 딥페이크를 배신하는가"를 누수 없는 실험으로 규명했다. 네 가지 탐지 패러다임이 모두 무너진 조작(NeuralTextures)이 **공간적으로는 조용하지만 시간적으로는 시끄럽다**는 것을 측정으로 밝히고, 그 진단이 지목한 직교축(시간)으로 벽을 뚫어 **공간+시간 이중브랜치 판별기**를 완성했다. 누수 0 in-dist AUC **0.940**(4 기법 구멍 없음), 미지 데이터셋 Celeb-DF cross-dataset **0.80**.

초록

이 프로젝트의 가치는 최종 성능뿐 아니라 **정직한 실패 지도**에 있다. 극적인 가설을 여덟 번 세웠고 여덟 번 데이터에 부딪혀 정정했다. 각 반증이 다음 실험을 더 정확하게 만들었고, "FaceSwap 을 콕 집어 0.52"라는 극적 서사를 "조작 계열마다 최적 탐지 축이 다르다"는 견고한 구조로 바꿨다. 최종 산출물은 ① 작동하는 이중브랜치 판별기(코드+웹앱+가중치), ② 누수 0 4 패러다임 벤치마크, ③ 조작 계열별 상보성의 정량적 규명, ④ 재현 가능한 전 과정 기록, ⑤ 재연=과평할 방향의 규명과 미지-재연 일반화 aug(§ 11), ⑥ 충실도 검증된 XAI(§ 12)이다.

1. 서론

1.1 배경과 출발점

초기 목표는 "재조작(challenge-response) 잔차 $|X - T(X)|$ 로 딥페이크를 판별한다"였다. 이 가설은 검증 과정에서 여러 문제가 드러났고(추론 시점 InSwapper 지문 혼입, 신원 거리 confound), 이를 정직하게 해체하며 **"무엇이 딥페이크를 배신하는가"**라는 더 근본적 질문으로 전환했다.

1.2 이 리포트가 다루는 것

- 진단: 저수준·외형·blending·foundation 네 패러다임의 누수 0 비교와 그 과정의 반증 연쇄
 - 돌파: NeuralTextures 벽의 규명과 시간 축을 통한 해결
 - 시스템: 공간+시간 이중브랜치 판별기와 성능
 - 일반화: 미지 데이터셋(Celeb-DF) cross-dataset 검증
 - 게이트: 상보성을 라우팅으로 착취할 수 있는가에 대한 사전 등록 실험
-

2. 데이터와 방법론

2.1 데이터셋

- **FaceForensics++ (FF++)** — original 500 + 4 조작(Deepfakes, Face2Face, FaceSwap, NeuralTextures) $\times$ 500 = 총 2,500 비디오. c23 압축, MTCNN 정렬 얼굴 크롭(224).
- **Celeb-DF v2** — real 590 + Celeb-synthesis(fake) 5,639. **학습에 전혀 쓰지 않은 미지 데이터셋**(다른 인물·조작·출처)으로 cross-dataset 일반화 측정에 사용.

2.2 방법론적 토대: Component Split (핵심)

FF++ fake A_B(A=대상, B=소스 신원)에서, 같은 사람이 train 과 test 에 동시에 있으면 모델이 "조작 흔적" 대신 "이 사람 얼굴"을 외워 지표가 부풀려진다(신원 누수).

- **이전 strict split 의 결함:** fake 를 "A·B 가 둘 다 같은 fold 일 때만" 포함 → 신원을 개별 배정하면 대부분 흩어져 **fake 의 86%가 버려짐**(500 개 중 68 개 생존, fold 당 8~22 개). 지표 신뢰 불가.
- **Component split:** fake A_B 를 간선 A-B 로 보고 union-find 로 연결요소 생성(285 개, 대부분 크기 2), 요소를 통째로 fold 에 배정 → **신원 누수 0 + fake 100% 보존**을 동시 달성.

이 방법론이 이 리포트 모든 수치의 신뢰 근거다. 이후 모든 실험은 component split 을 사용한다.

3. 진단: 반증의 연쇄

극적 가설을 세우고 가장 싼 falsifying 실험으로 깨는 방식(falsify-first)으로 진행했다. 반증된 가설도 1 급 결과로 기록한다.

#	가설	결과	핵심
A	FaceSwap 은 고주파 부호가 반대다	반증	4 기법 전부 고주파 감소. FaceSwap 은 변화량이 최소(DF 의 1/7)
B	흔적은 합성 경계 seam 에 숨어있다	반증	FaceSwap seam 은 DF 의 1/10. 경계에도 최소
C	압축이 저수준 흔적을 파괴한다	반증	Δ 붕괴는 분산 스케일링 착시. 효과크기·AUC 는 보존
D	FaceSwap=0.52, 유일한 사각지대	과장	잔차 입력 핸디캡. RGB 모델은 0.60, NT 도 0.55
E	저수준 일반의 한계인가?	공정검증	SBI(blending 특화)로 반증 시도 → SBI 도 FS 0.64
F	NT 벽 = 그냥 약한 백본 탓?	공정검증	CLIP L/14·LN-tune 으로도 NT 0.56 요지부동 = 진짜 벽

3.1 방법론적 교훈 (재사용 가능)

1. **평균차이(Δ) $\neq$ 판별력.** 분산이 함께 변하면 오도한다 → Cohen's d / AUC 로 검증.
2. **작은 n 의 상관은 outlier 하나가 만든다.** seam↔난이도 "단조 관계"는 DF 한 점의 착시였다.
3. **"그 부류가 안 된다"는 그 부류의 SOTA 로 공정 반증하라.** 비특화 구현의 한계일 수 있다.

4. 4 패러다임 벤치마크

"가짜의 정체는 어디 있나"에 대한 근본적으로 다른 네 가설을, 같은 누수 0 · LOMO(미지 기법) 프로토콜에서 정면 비교했다.

LOMO cross-manipulation AUC ($\pm$ std, 5-fold):

패러다임 (모델)	Deepfakes	Face2Face	FaceSwap	NeuralTextures	in-dist
외형 (ConvNeXt)	0.824	0.652	0.582	0.549	0.929
잔차 (SRM+Bayar)	0.782	0.652	0.524	0.572	0.849
blending (SBI)	0.798	0.534	0.644	0.480	—
foundation (CLIP L/14)	0.923	0.673	0.774	0.556	0.832

핵심 발견: - **NeuralTextures** 는 4 패러다임 공통의 벽 — 전부 ≤ 0.57 . 백본 스케일(B/16→L/14)도 미세조정(LN-tune 0.562)도 NT 만 못 움직인다 → **모델 용량이 아니라 정보 수준의 벽.** - **FaceSwap "사각지대"**는 약한 백본 탓이었다 — CLIP L/14 가 0.774. 강한 foundation 이면 잘 잡는다. - **백본 이원화:** in-dist 는 ConvNeXt(0.929) 승, cross-manip 은 CLIP L/14 승.

5. 돌파구: 시간 축

5.1 진단

시도한 네 축은 전부 **단일 프레임 공간 신호**였다. NeuralTextures 는 입 텍스처를 프레임마다 신경망이 재생성한다 → 공간적으론 조용해도 **시간적으론 flicker**. 진단이 지목한 직교축 = 시간.

5.2 검증과 대조군

얼굴 크롭 연속프레임(원본 비디오 불필요)에서 **픽셀 시간특징 8 개** + LogReg:

method	공간(CLIP L/14)	시간(픽셀 8feat)
Deepfakes	0.923	0.729
Face2Face	0.673	0.707
FaceSwap	0.774	0.513 (시간축 무신호)
NeuralTextures	0.556	0.777 (시간축 강신호)

method	공간(CLIP L/14)	시간(픽셀 8feat)
--------	---------------	--------------

NT 0.556 → 0.777(손특징 8 개 + 로지스틱만으로). **FaceSwap 대조군(0.513)이 결정적:** temporal 이 "가짜 티"를 잡는 거였으면 FaceSwap 도 높아야 하는데 우연 수준 → temporal 은 **진짜 얼굴 동역학 조작**을 잡는다(재연 계열 ↑, 정적 paste ↓). **공간(FaceSwap) × 시간(NeuralTextures) 직교 상보성 확정.**

문헌 확인: NT 최난이도 = 문헌 동의. NT 최선택 = temporal/mouth(LipForensics). **진단이 문헌 SOTA 방향과 독립적으로 일치.**

5.3 딥 시간 브랜치

손특징은 ~0.78 에서 포화(다영역 27feat+GBM 으로도 0.756). **mc3_18(입 crop 16 프레임 3D-CNN, Kinetics 사전학습)** 엔드투엔드 학습 → in-dist per-method:

method	공간	손 temporal	딥 temporal
--------	----	------------	------------

Deepfakes	0.926	0.734	0.919
-----------	-------	-------	-------

Face2Face	0.786	0.713	0.890
-----------	-------	-------	-------

FaceSwap	0.878	0.516	0.869
----------	-------	-------	-------

NeuralTextures	0.707	0.784	0.873
-----------------------	-------	-------	--------------

NT 를 0.71/0.78 → **0.873** 으로 끌어올렸고, **약한 기법이 하나도 없다**(전부 0.87~0.92).

6. 최종 시스템

6.1 아키텍처

```

video/frames → 얼굴검출(MTCNN) → [공간] 전체얼굴 → ConvNeXt (외형 아티팩트)
               [시간] 입클리프(16f) → 3D-CNN (텍스처 flicker)
               → robust fusion → fake 확률
  
```

6.2 성능 (in-dist, 누수 0, ConvNeXt 공간 + 딥 temporal)

method	공간	시간	융합
Deepfakes	0.975	0.919	0.975
Face2Face	0.939	0.892	0.945
FaceSwap	0.956	0.870	0.950
NeuralTextures	0.825	0.873	0.891
전체 AUC	0.924	0.888	0.940

4 기법 전부 ≥ 0.89 , 구멍 없음. NT(4 패러다임 벽, 0.55) $\rightarrow$ 최종 제품 0.891. stacking $\approx$ mean(둘 다 0.940) $\rightarrow$ 게이트 불필요, 단순 평균으로 충분.

6.3 작동 데모 (infer.py)

입력	공간	시간	판정
original (real)	0.014	0.007	REAL
Deepfakes	0.918	0.181	FAKE (공간이 잡음)
FaceSwap	0.978	0.880	FAKE
NeuralTextures	0.829	0.898	FAKE (시간이 잡음)
SimSwap (미지 조작)	0.068	0.929	FAKE (시간이 미지 조작 포착)

산출물: infer.py(CLI), app.py(영상 업로드 웹앱, werkzeug), 5+3 fold 앙상블 가중치. GitHub 팀 저장소에 배포.

7. 일반화 검증 (cross-dataset)

FF++로 학습한 판별기를 미지의 Celeb-DF v2 에 적용(n=2,086).

브랜치	AUC	3-branch 융합	AUC
공간 (ConvNeXt)	0.800	공간+시간	0.785
시공간 (3D-CNN)	0.634	공간+CLIP	0.766
CLIP L/14	0.709	3-branch 평균	0.771

7.1 두 가지 정직한 교정 (일화 ≠ 벤치마크)

- **G. "temporal 이 이미지 조작에 더 강함" → 반증.** Celeb-DF 는 swap 계열이라 시간적으로 안정 → temporal 0.634 « spatial 0.800. (SimSwap 한 케이스는 운 좋은 일화였다.)
- **H. "CLIP 이 cross-dataset 도 올림" → 반증.** CLIP 0.709 < ConvNeXt 0.800. **cross-manip ≠ cross-dataset:** frozen CLIP 은 cross-manip 최강이지만, 이미지 데이터셋엔 **끝까지 fine-tune 한 ConvNeXt 가 더 잘 전이**된다.

결론: 제품은 FF++에 감하지 않고 이미지 데이터셋에 **AUC 0.80** 으로 일반화(과적합 아님). 정직하게 견고하되 SOTA(0.85~0.93)엔 못 미친다. 브랜치 분해가 모든 발견(swap=공간, 재연=시간)과 일관.

8. 게이트 실험 (사전 등록)

질문: 상보성이 실재한다면, 입력 조건부 라우터(게이트)가 고정 fusion 을 이기는가? in-dist 에션 두 브랜치가 모두 강해 게이트가 할 일이 없으므로 **LOMO 에서** 검증. 게이트는 조작 라벨을 절대 보지 못하며, 누수 0 프로토콜 (held_out≠M & fold≠f 로 학습 → held_out=M & fold=f 로 평가)로 학습.

held-out	spatial	temporal	mean	stacking	gate	oracle
Deepfakes	0.897	0.723	0.896	0.910	0.911	0.897
Face2Face	0.679	0.703	0.744	0.721	0.735	0.708
FaceSwap	0.744	0.510	0.643	0.636	0.650	0.744
NeuralTextures	0.588	0.773	0.726	0.637	0.668	0.773

	held-out	spatial	temporal	mean	stacking	gate	oracle
평균		0.727	0.677	0.752	0.726	0.741	0.781

판정: 실패(사전 등록된 실패 케이스). 게이트(0.741)가 단순 mean fusion(0.752)보다 나쁘고, 더 나은 브랜치에 근접 못 한다(FS 0.650«0.744, NT 0.668«0.773). 게이트 weight 가 라우팅을 거꾸로/무의미하게 냈다 (FaceSwap→0.45, NeuralTextures→0.69, 필요한 방향과 반대).

정밀한 결론(oracle 0.781 이 못박음): 완벽 라우팅은 실제로 이득이 있고(oracle » mean) fusion 코드도 무결하다. 즉 상보성은 원리적으로 착취 가능하지만, 관찰 가능한 feature 로는 미지 조작을 라우팅하는 정보를 얻을 수 없다. → mean fusion 이 최선의 단순 선택.

9. 종합 결과

- **방법론:** component split — 신원 누수 0, fake 100% 보존 (이전 프로토콜 지표 부풀림 규명)
- **벤치마크:** 4 패러다임(외형·잔차·blending·foundation) × 누수 0 × 오차막대
- **핵심 발견:** 조작 계열마다 최적 축이 다르다 — swap=공간, 재연=시간. NT 는 정보수준 벽
- **돌파:** 시간 축이 NT 를 0.55 → 0.89 로 뚫음 (진단이 설계를 정당화)
- **제품:** 공간+시간 이중브랜치, in-dist 0.940, 구멍 없음, 실행 가능한 판별기+웹앱
- **일반화:** Celeb-DF cross-dataset 0.80 (과적합 아님)
- **게이트:** 상보성 실재하나 라우팅은 학습 불가 — mean fusion 이 최선 (사전등록 실패=1 급 결과)

반증된 가설 8 개(A~F + G·H)와 게이트 실패가 이 프로젝트의 지적 골격이다.

10. 기여 · 한계 · 향후

10.1 기여 (정직한 평가)

개별 부품(ConvNeXt·3D-CNN·CLIP·temporal)은 알려진 기술이고, "NT 가 어렵다 / temporal 이 잡는다"도 문헌이 안다. 이 작업의 가치는 완성도 + 누수 0 벤치마크 + 정직한 실패 지도 + 진단→설계 논리, 그리고 그 전부가 재현

가능한 코드로 남았다는 데 있다.

10.2 한계

- cross-dataset 0.80 은 견고하나 SOTA(0.85~0.93)엔 못 미침.
- 시간 브랜치는 재연(NT) 전문가 — swap 중심 데이터(Celeb-DF)엔 약함.
- 게이트가 안 되므로 조작 계열별 최적화는 고정 fusion 에 의존.
- Celeb-DF 평가는 공식 518 test split 이 아닌 전체/샘플(리스트 부재).

10.3 향후 방향 (독창성 후보)

1. **Temporal Self-Blend** — SBI(공간 self-blend)가 못 잡는 재연을, 그 정체를 real 영상에 합성 주입한 "시간적 pseudo-fake"로 학습. (→ § 11 에서 수행: 정체는 flicker 가 아니라 **과평활**이었고, 일반 개념은 선행연구(STRD·VB)임을 확인. 생존 각도는 "기존과 반대 방향".)
2. **시간-주파수 서명** — 영역별 시간 신호의 주파수 스펙트럼. 자연 모션=저주파, 재연=부자연 고주파. 공간 주파수는 포화, 시간 주파수는 덜 탐구 + 해석 가능.
3. **조건부 재조작 응답** — 원래 challenge-response 를 공간×시간 프로파일 이동의 관점으로 부활.

11. 확장: 재연 = 과평활 방향과 강건성 aug

§ 10.3 에서 후보로 남긴 "Temporal Self-Blend"를 실제로 수행하고 정직하게 정정했다.

11.1 정체 규명 — flicker 가 아니라 과평활

NeuralTextures 의 시간 서명은 떨림(flicker)이 아니라 **텍스처 시간 과평활**(프레임 간 미세변동 상실)이었다. 첫 flicker 가설은 반증(NT 0.558)됐고, 특징 분석으로 방향을 과평활로 정정하니 통과(NT 0.700). 광학흐름 모션보정 후에도 텍스처 분리력이 남아(d_resid AUC 0.762 > 모션 0.721) **모션 무관**임을 확인했다.

11.2 방향이 핵심 — 기존 self-blend 와 정반대

합성 방향	NeuralTextures(재연) AUC
-------	------------------------

과평활(우리)	0.70
---------	------

교란 = STRD 0.22 (반전)

warp-drift = VB 0.31 (반전)

기존 temporal self-blend(STRD arXiv:2207.10402, VB 2408.17065)는 시간 **교란/드리프트** 방향인데, 재연을 잡으려면 **정반대(과평활)**가 필요하다.

11.3 일반화 — 미지 재연으로 전이 (LOMO)

swap 만 지도학습하고 재연을 held-out(leave-reenactment-out):

방식

재연 held-out AUC

A 지도(swap 만) 0.706

B 지도 + 과평활 aug 0.733 (NT +0.052)

C real-only 과평활 0.644 (단 NT 0.701 > A)

이득이 과평활 지배 기법(NT)에만 몰려(F2F +0.001) 메커니즘 근거가 됐다.

11.4 배포 — 앙상블 hedge + 캘리브레이션

- 직접 교체(aug 만): in-dist -0.010(FaceSwap 붕괴) → **기각**.
- **6 모델 앙상블**(표준 3 + 과평활-aug3): in-dist 무손실(+0.004, NT +0.009), Celeb-DF cross 시공간 AUC +0.091.
- 캘리브레이션(FF++ Platt fit, Celeb-DF 독립검증): 고정 0.5 BACC FF++ +0.081 / Celeb +0.050, AUC 불변.

정직한 위치. 일반적 "temporal self-blend" 개념은 선행연구. 생존한 좁은 각도는 "재연 = 과평활, 기존과 반대 방향"(모션 통제)이며, aug 는 in-dist 부스터가 아니라 **일반화 도구**임을 반증을 통해 정정했다. 절대 이득은 완만 (+0.004~0.055).

12. XAI: 설명가능성과 충실도 검증

"어디가 fake 인가"를 시각화하되, 히트맵은 '모델 주목 영역'이지 물증이 아니므로 **충실도를 측정**했다.

12.1 시공간 Grad-CAM 충실도 (falsify-first)

정답 = FF++ 풀프레임 |fake - original|(픽셀정렬, 배경 diff $\approx$ 0.6). 크롭 diff 는 프레임별 독립 검출로 정렬이 깨져(입 8.5 < 나머지 24.1) 풀프레임으로 교정했다(반증 $\rightarrow$ 수정).

	pointing-game	CAM-vs-mask AUC
학습 6 모델	0.516	0.706
랜덤가중치(Adebayo sanity)	0.214	0.591
우연	0.200	0.500

학습 CAM 이 실제 조작영역을 **우연의 2.6 배**로 국소화하고, 랜덤모델은 우연 수준(Adebayo sanity 통과) = 충실도가 **학습에서 비롯**. "그렇듯하지만 무의미"(Adebayo et al. 2018)를 반증했다.

12.2 웹 통합과 정직한 한계

/api/predict 가 판정 + 공간·시공간 Grad-CAM 히트맵(base64) + 브랜치 반응을 반환한다. 두 가지를 정직하게 표기: (1) 히트맵은 주목영역(충실도 병기), 물증 아님. (2) 브랜치 기반 계열판별(swap/재연)은 per-sample 신뢰 못 함(공간분기가 재연에도 강하게 반응) $\rightarrow$ family 를 '단정'에서 '서술 + 가설'로 낮췄다. pointing 0.52 라 절반은 빗나간다.

부록 A. 실험 인덱스

실험	내용	스크립트
진단 1·2	고주파 부호 / 경계 seam	hf_sign_probe.py, hf_boundary_probe.py
진단 3	residual SRM LOMO	train_remanip_srm.py

실험	내용	스크립트
진단 4~7	압축 붕괴 / 검증 / 페어분해 / 효과크기	degrade_collapse.py, verify_degrade.py, paired_breakdown.py, effect_size.py
진단 8	APP/SRM LOMO per-method	train_direct_face_classifier.py
진단 9	SBI 공정 baseline	train_sbi_baseline.py
CLIP 배터리	frozen B/16·L/14 + LN-tune	clip_probe_lomo.py, clip_lntune.py
시간	픽셀/enriched/딥 temporal	temporal_probe.py, temporal_enriched.py, clip_temporal.py
융합	in-dist / 개선 (ConvNeXt+stacking)	fusion_probe.py, improved_fusion.py
cross-dataset	Celeb-DF 2·3 branch	eval_celebfd.py, eval_celebfd_3branch.py
게이트	OOF 생성 + 사전등록 실험	gate_oof_generate.py, gate_experiment.py
§ 11 과평할 방향	정체 규명·방향 대조·confound	temporal_selfblend_probe.py, direction_compare.py, confound_check.py
§ 11 aug 검증	LOMO·강도 스윙·배포 재학습	lomo_verify.py, sweep_aug.py, deploy_retrain.py, deploy_finalize.py
§ 11 캘리브레이션	Platt 보정(FF++ fit, Celeb 검증)	calibrate_temporal.py
§ 12 XAI	Grad-CAM·충실도(pointing)	gradcam_demo.py, temporal_faithfulness.py, xai.py
cross-dataset 준비	범용 얼굴 추출기	extract_faces_generic.py
제품	추론/웹앱(XAI 통합)	infer.py, app.py

부록 B. 관련 문서

- EXPERIMENT_LOG_2026-07-09.md — 시간순 상세 로그(반증 과정 포함)

- deepfake_detector/ — 배포 가능한 판별기(코드+가중치+발표페이지). GitHub seelhwan 브랜치.

부록 C. 방법론 상세 (모델 · 원리 · 수식)

C.1 전처리

프레임별 얼굴을 MTCNN[9]으로 검출 · 정렬해 224×224 크롭. **공간 브랜치**는 전체 얼굴, **시간 브랜치**는 입영역 ROI(세로 [0.50, 0.96] · 가로 [0.16, 0.84] 비율)를 112×112 로 리샘플하고 클립 길이 $T=16$. 정규화는 공간=ImageNet, 시간=Kinetics 통계.

C.2 공간 브랜치 — ConvNeXt-tiny [1]

ConvNeXt 블록의 핵심 연산(입력 x , 채널 C):

```
z = DWConv7x7(x)                                # depthwise: 채널별 큰 커널 공간 혼합
z = LayerNorm(z)
z = Linear(C→4C); z = GELU(z); z = Linear(4C→C)  # inverted bottleneck (Transformer MLP)
x_out = x + DropPath(z)                           # residual
```

- **Patchify stem**: 4×4 stride-4 conv 로 비겹침 패치 임베딩(ViT patch embedding 모방).
- **depthwise 7×7** 은 self-attention 의 "공간 위치 혼합"을 큰 커널로 근사 → 넓은 수용영역을 저비용으로.
- 계층 깊이 (3,3,9,3), 채널 (96,192,384,768). ImageNet-22k 사전학습 → 1k 미세조정[10].
- 분류 head: $h = \text{Linear}(\text{LayerNorm}(\text{GAP}(\text{feat})))$, $p_{\text{spatial}} = \sigma(h)$. **5-fold 앙상블** 평균.

왜 swap 에 맞나: 얼굴 교체는 blending 경계 · 색/질감 불일치를 **단일 프레임 공간 패턴**으로 남긴다. 강한 in22k 백본의 넓은 수용영역이 이를 포착한다.

C.3 시간 브랜치 — mc3_18 (Mixed 3D Convolution) [2]

3D 컨볼루션(입력 $X \in \mathbb{R}^{C \times T \times H \times W}$):

$$Y(c', t, i, j) = \sum_c \sum_{\{\tau, u, v\}} W(c', c, \tau, u, v) \cdot X(c, t+\tau, i+u, j+v) + b$$

시간 인덱스 τ 가 합에 포함 $\rightarrow$ 프레임 간 동역학을 **직접** 학습.

MC3의 3D $\rightarrow$ 2D 전환(핵심): ResNet-18 골격에서 **초기** residual 그룹은 3D conv(시간 커널 $k_t=3$), **후기** 그룹은 2D conv($k_t=1 \rightarrow$ 시간 혼합 없음)로 둔다. - 근거[2]: 모션 정보는 저수준(초기 층)에서 가장 유용하고, 깊어질수록 정적 의미표현으로 충분하다. 순수 3D(R3D)는 파라미터·연산이 크고 과적합 위험이 커 — MC3는 **초기만 3D로 모션을 잡고 이후 2D로 효율화**한다(R2+1D는 3D를 공간 2D+시간 1D로 분해하는 또 다른 절충). - 딥페이크 해석: 재연의 이상은 "입 텍스처가 프레임마다 어떻게 변하나"라는 **저수준 동역학** $\rightarrow$ 초기 3D 층이 이를 포착. 입력을 입 ROI로 제한해 신호를 증폭(전체 얼굴 3D-CNN은 방향 효과가 희석됨을 실측). - Kinetics-400 사전학습[3]. head: $p_{\text{temporal}} = \sigma(\text{Linear}(\text{GAP}_{\{t,h,w\}}(\text{feat})))$. **6-모델 앙상블**(§ C.5).

C.4 과평활 pseudo-fake (real-only) [ours; cf. 4,5,6]

입 ROI 프레임열 $\{x_t\}$ 에 시간 이동평균 $\bar{x}_t = (x_{t-1} + x_t + x_{t+1})/3$ 를 정의하고, 혼합비 $\alpha \sim U(0.55, 0.8)$ 로

$$x'_t = (1-\alpha) \cdot x_t + \alpha \cdot \bar{x}_t \quad (\text{ROI 내, } t=1..T)$$

프레임 간 미세변동을 감쇠(과평활)한 "시간적 가짜". 원본을 음성(0), x' 을 양성(1)으로 학습해 **"재연=과평활"** 귀납편향을 주입한다. 기존 self-blend(SBI[4]는 공간, STRD[5]·VB[6]는 시간 **교란/드리프트**)와 방향이 정반대 — 이것이 규명·검증된 좁은 각도.

C.5 앙상블 + Platt 캘리브레이션 [7,8]

앙상블: $p_{\text{temporal}} = (1/M) \sum_m \sigma(f_m(\text{clip}))$, $M=6$ (표준 3 + 과평활-aug 3). Platt scaling[7]: 로짓 $\ell = \log(p/(1-p))$ 에 대해 보정확률

$$q = \sigma(a \cdot \ell + b), \quad (a, b) = \operatorname{argmin} -\sum_i [y_i \log q_i + (1-y_i) \log(1-q_i)] \quad (\text{NLL})$$

FF++ leak-free 검증점에서 fit. 단조변환이라 **AUC(순위) 불변**, 의사결정 임계 0.5만 재정렬한다. Celeb-DF로 독립검증(전이 확인). $a < 1$ 이면 온도 스케일링[8]과 동형(과신뢰 완화). 실측 $a=0.714$, $b=-0.907$.

C.6 융합·판정 (robust verdict)

$$p_{\text{fused}} = (p_{\text{spatial}} + p_{\text{temporal}})/2 \\ \hat{y} = \text{FAKE} \Leftrightarrow p_{\text{fused}} \geq 0.5 \quad \vee \quad \max(p_{\text{spatial}}, p_{\text{temporal}}) \geq 0.85$$

OR-0.85 는 단일 축만 강하게 반응하는 미지 조작(swap 만 · 재연만)에 대한 재현을 보강.

C.7 Component split (union-find)

fake video_id "A_B"를 간선 (A,B)로 보고 union-find 로 연결성분을 형성, KFold 를 성분 인덱스에 적용해 fold 를 나눈다 → 모든 신원 n 에 대해 fold(n)이 유일 → train/test 신원 교집합 = $\emptyset$. fake 전량 보존(strict split 은 86% 폐기).

C.8 Grad-CAM 수식 [11] + 충실도

공간(2D, 특징맵 $A^k \in \mathbb{R}^{H \times W}$, 점수 y):

$$\begin{aligned} \alpha_k &= (1/Z) \sum_i \sum_j \partial y / \partial A^k_{ij} & \# \text{ 채널 중요도} &= \text{그래디언트 GAP} \\ L &= \text{ReLU}(\sum_k \alpha_k A^k) & \# \text{ 양의 기여만} &\rightarrow \text{업샘플} \end{aligned}$$

시간(3D, $A^k \in \mathbb{R}^{T \times H \times W}$): $\alpha_k = (1/Z) \sum_{t,i,j} \partial y / \partial A^k_{tij}$, $L(t,i,j) = \text{ReLU}(\sum_k \alpha_k A^k(t,i,j)) \rightarrow$ (T,112,112) 삼선형 업샘플로 **프레임별** 히트맵. 충실도: 정답 $G = \mathbb{1}[|\text{fake-orig}| \geq 80 \text{ 퍼센타일}]$. pointing-game = $(1/N) \sum \mathbb{1}[\argmax L \in G]$, 우연 $\approx |G|/\text{전체} = 0.20$. Adebayo sanity[12]: 랜덤가중치 모델 pointing 이 우연 수준이면 충실도가 **학습에서 비롯됨**을 보장(실측 학습 0.516 vs 랜덤 0.214).

C.9 학습 설정

손실 BCEWithLogits, 옵티마이저 AdamW(lr 3e-4, wd 1e-4), 스케줄 OneCycleLR(pct_start 0.15), AMP(fp16), 클래스균형 WeightedRandomSampler. 가중치 저장 fp16(GitHub 100MB 대응).

부록 D. 참고문헌

- [1] Z. Liu et al., "A ConvNet for the 2020s," **CVPR 2022**. (ConvNeXt)
- [2] D. Tran et al., "A Closer Look at Spatiotemporal Convolutions for Action Recognition," **CVPR 2018**. (MC3·R2+1D)
- [3] W. Kay et al., "The Kinetics Human Action Video Dataset," arXiv:1705.06950, 2017.
- [4] K. Shiohara, T. Yamasaki, "Detecting Deepfakes with Self-Blended Images," **CVPR 2022**. (SBI)

- [5] "Self-supervised Temporal Regularity Disruption for deepfake video detection," arXiv:2207.10402. (STRD)
 - [6] "Video-Level Blending for temporal forgery," arXiv:2408.17065. (VB)
 - [7] J. Platt, "Probabilistic Outputs for Support Vector Machines," 1999. (Platt scaling)
 - [8] C. Guo et al., "On Calibration of Modern Neural Networks," **ICML 2017**. (temperature scaling)
 - [9] K. Zhang et al., "Joint Face Detection and Alignment using MTCNN," IEEE SPL 2016.
 - [10] J. Deng et al., "ImageNet," CVPR 2009 (+ ImageNet-21k/22k 사전학습).
 - [11] R. Selvaraju et al., "Grad-CAM: Visual Explanations from Deep Networks," **ICCV 2017**.
 - [12] J. Adebayo et al., "Sanity Checks for Saliency Maps," **NeurIPS 2018**.
 - [13] A. Rossler et al., "FaceForensics++: Learning to Detect Manipulated Facial Images," **ICCV 2019**.
-

작성: 딥페이크 판별 프로젝트 · FaceForensics++ / Celeb-DF v2 · 공간×시간 이중브랜치 원칙: 반증된 가설도 1
급 결과. 누수 0 프로토콜. 일화가 아니라 벤치마크.